Prédire l'inclusion financière en Afrique

Projet intégrateur en Data Science

Membres du groupe

1) ADEFOULOU Phanouël
2) AGUIDI Othniel
3) AKPLOGAN DJIBODE Médard
4) AYELLA Flamine

Sous la supervision :

Msc. Osias Noël TOSSOU

Année scolaire : 2026 - 2027

Résumé

Contexte. En Afrique de l'Est, seule une minorité d'adultes possède un compte bancaire. Ce projet exploite les données d'enquêtes FinScope (2016-2018) du jeu « Financial Inclusion in Africa » de Zindi (Kenya, Rwanda, Tanzanie, Ouganda ; 23 524 personnes) pour prédire si une personne possède un compte à partir de 11 caractéristiques socio-démographiques et, surtout, pour comprendre quels facteurs pèsent le plus.

Démarche. Après un audit de qualité et une analyse exploratoire détaillée, six configurations (régression logistique, Random Forest et XGBoost, avec plusieurs stratégies de gestion du déséquilibre : 14,1 % seulement de personnes bancarisées) ont été comparées par validation croisée. XGBoost avec pondération des classes a été retenu.

Résultats. Sur 4 705 personnes de test, le modèle atteint un ROC-AUC de 0,866, une Average Precision de 0,579 (0,141 pour un classement au hasard) et un rappel de 76,9 % pour la classe « a un compte », au prix d'une précision de 37,6 %. L'éducation est de loin le facteur le plus déterminant, devant l'emploi, le pays et l'accès au téléphone. Sur les six hypothèses issues de l'exploration, quatre sont confirmées, une l'est partiellement et une n'est pas confirmée.

Déploiement. Le modèle est mis à disposition par une API FastAPI et un formulaire web, avec un réentraînement quotidien qui ne remplace le modèle que s'il est meilleur, le tout conteneurisé avec Docker (section 10). Le code est publié sur GitHub : https://github.com/Othniel-Ken/financial-inclusion-africa.

Limites. Données de 2016 à 2018 couvrant quatre pays d'Afrique de l'Est, effet du pays confondu avec celui de l'année, associations et non causalité, bruit irréductible dû aux profils contradictoires.

Mots-clés : inclusion financière, classification binaire, déséquilibre des classes, XGBoost, Afrique de l'Est, déploiement.

Table des matières

1. Problématique métier 4
1.1 Contexte 4
1.2 Acteurs concernés et enjeux 4
1.3 Formulation en problème de science des données 4
1.4 Intérêt et impact potentiel 4
2. Description du jeu de données 4
2.1 Source et taille 4
2.2 Variables 5
3. Qualité des données 5
4. Statistiques descriptives 6
5. Visualisations et premiers enseignements 7
5.1 Une cible fortement déséquilibrée, et de grandes différences entre pays 7
5.2 Éducation et situation professionnelle : les facteurs les plus discriminants 8
5.3 L'âge : une relation en cloche 9
5.4 Téléphone, milieu de vie et genre 9
5.5 Autres variables 10
6. Hypothèses formulées 10
7. Nettoyage effectué et jeu de données livré 11
Synthèse de l'analyse exploratoire 11
8. Prétraitement et modélisation 11
8.1 Choix des algorithmes et des métriques 11
8.2 Prétraitement et feature engineering 12
8.3 Séparation des données 12
8.4 Gestion du déséquilibre des classes 12
8.5 Entraînement et comparaison des modèles 13
8.6 Sélection du modèle final 13
9. Évaluation et résultats 13
9.1 Performances sur le jeu de test 13
9.2 Matrice de confusion 14
9.3 Courbes ROC et précision-rappel 14
9.4 Choix du seuil de décision 15
9.5 Importance des variables 15
9.6 Vérification des hypothèses issues de l'EDA 16
10. Déploiement et automatisation 16
10.1 Vue d'ensemble 16
10.2 API de prédiction 17
10.3 Interface web 18
10.4 Réentraînement automatique 18
10.5 Conteneurisation avec Docker 19
10.6 Reproduire le projet 19
11. Limites et perspectives 19
11.1 Limites 19
11.2 Perspectives 20
12. Conclusion 20
Références 21

Liste des tableaux

Tableau 1 - Répartition par pays et année 5
Tableau 2 - Dictionnaire des variables du fichier brut (8 des 11 variables explicatives sont catégorielles)..... 5
Tableau 3 - Audit de qualité du fichier Train 6
Tableau 4 - Variables numériques (Train)..... 6
Tableau 5 - Hypothèses issues de l'EDA (verdicts : tableau 11) 10
Tableau 6 - Opérations de nettoyage (notebook EDA_Inclusion_Financiere.ipynb) 11
Tableau 7 - Variables utilisées par le modèle et prétraitements appliqués..... 12
Tableau 8 - Validation croisée à 5 plis (classe « a un compte »)..... 13
Tableau 9 - Performances du modèle final sur le jeu de test 14
Tableau 10 - Précision, rappel et F1 selon le seuil de décision (jeu de test)..... 15
Tableau 11 - Verdict sur les hypothèses H1 à H6..... 16
Tableau 12 - Organisation du dépôt GitHub 17
Tableau 13 - Points d'accès de l'API 17
Tableau 14 - Variables d'entrée du modèle et règles de dérivation (implémentées dans `app/main.py`) 17
Tableau 15 - Deux exemples d'appel à `/predict` 18

Liste des figures

Figure 1 - Distribution de l'âge, de la taille du ménage et de l'âge par pays..... 7
Figure 2 - Répartition de la variable cible et taux de bancarisation par pays..... 7
Figure 3 - Taux de bancarisation par niveau d'éducation et par situation professionnelle 8
Figure 4 - Taux de bancarisation (%) selon le pays et le niveau d'éducation..... 8
Figure 5 - Taux de bancarisation par tranche d'âge 9
Figure 6 - Bancarisation selon le téléphone et le milieu de vie, et selon le genre et le pays 9
Figure 7 - Force d'association de chaque variable avec la cible (V de Cramér). Tous les tests du khi-deux ont une p-valeur inférieure à 10 puissance -40. 10
Figure 8 - Matrice de confusion du modèle final (jeu de test) 14
Figure 9 - Courbe ROC et courbe précision-rappel (jeu de test)..... 14
Figure 10 - Importance des variables par permutation (baisse de l'Average Precision) 15
Figure 11 - Formulaire web : deux profils testés (score de 82,6 % à gauche, 4,2 % à droite) 18

1. Problématique métier

1.1 Contexte

En Afrique subsaharienne, une grande partie de la population adulte n'a toujours pas de compte dans une banque ou auprès d'un opérateur de mobile money. L'accès à un compte est la porte d'entrée vers l'épargne sécurisée, le paiement dématérialisé, le crédit et l'assurance. Il est reconnu comme un levier de développement économique et de réduction de la pauvreté. Les enquêtes Finscope, dont sont issues nos données, mesurent précisément cet accès à partir d'entretiens auprès de ménages.

1.2 Acteurs concernés et enjeux

Acteur	Ce qu'il cherche	Enjeu
Banques commerciales	Identifier les segments non servis mais solvables	Élargir la clientèle, adapter les produits d'entrée de gamme
Microfinance et coopératives	Cibler les populations exclues, souvent rurales	Rentabilité de la proximité, risque de crédit
Opérateurs de mobile money	Convertir les détenteurs de téléphone en clients financiers	Croissance des usages, interopérabilité avec les banques
Régulateurs, banques centrales, gouvernements	Mesurer l'exclusion et piloter les politiques d'inclusion	Suivi d'indicateurs, éducation financière, ciblage des aides
Personnes exclues	Accéder à des services adaptés à leur situation	Sécurité de l'épargne, résilience face aux chocs

1.3 Formulation en problème de science des données

Il s'agit d'un problème de **classification binaire supervisée** : à partir de 11 caractéristiques socio-démographiques d'une personne (pays, année, milieu urbain ou rural, accès à un téléphone, taille du ménage, âge, sexe, lien avec le chef de ménage, situation matrimoniale, niveau d'éducation, type d'emploi), prédire si elle possède un compte bancaire (*bank_account* = 1) ou non (0). L'objectif est double : (a) prédire une probabilité individuelle d'avoir un compte, (b) **comprendre quels facteurs pèsent le plus**, ce qui est l'apport principal pour les acteurs ci-dessus.

1.4 Intérêt et impact potentiel

Un modèle de ce type permet de cibler les campagnes d'inclusion plutôt que de les diffuser à l'aveugle, d'estimer le taux de bancarisation de zones ou de profils où l'enquête n'a pas été menée, et de simuler l'effet d'un changement (par exemple, que se passerait-il si l'accès au téléphone progressait ?). Il convient toutefois de rester prudent : les associations observées ne prouvent pas des relations de cause à effet, et le modèle décrit des profils, pas des intentions individuelles.

2. Description du jeu de données

2.1 Source et taille

Le jeu de données « Financial Inclusion in Africa » provient de la plateforme Zindi. Il est fourni en deux fichiers : **Train.csv** (23 524 lignes, 13 colonnes, cible incluse) et **Test.csv** (10 086 lignes, 12 colonnes, sans la cible). L'ensemble représente donc 33 610 personnes, ce qui correspond aux « environ 33 600 » annoncés dans la fiche de projet ; le jeu d'entraînement seul n'en contient que 23 524. Comme le fichier Test n'a pas de cible, **toutes les analyses de ce rapport portent sur Train.csv**, et l'évaluation des modèles devra se faire sur une partie de Train mise de côté (voir section 8).

Pays	Année d'enquête	Lignes Train	Lignes Test	Taux de bancarisation (Train)
Rwanda	2016	8 735	3 745	11,5 %
Tanzanie	2017	6 620	2 839	9,2 %
Kenya	2018	6 068	2 601	25,1 %
Ouganda	2018	2 101	901	8,6 %
Total		**23 524**	**10 086**	**14,1 %**

Tableau 1 - Répartition par pays et année

2.2 Variables

Variable	Type	Description / modalités
country	catégorielle (4)	Kenya, Rwanda, Tanzanie, Ouganda
year	numérique discrète	2016, 2017 ou 2018 (déterminée par le pays, sauf Kenya et Ouganda)
uniqueid	identifiant	Numéro du répondant, répété d'un pays à l'autre
bank_account	**cible** (Yes/No)	Possède un compte bancaire
location_type	catégorielle (2)	Rural / Urbain
cellphone_access	catégorielle (2)	A accès à un téléphone portable : oui / non
household_size	numérique	Nombre de personnes du ménage (1 à 21)
age_of_respondent	numérique	Âge en années (16 à 100)
gender_of_respondent	catégorielle (2)	Femme / Homme
relationship_with_head	catégorielle (6)	Chef de ménage, conjoint, enfant, parent, autre parent, non apparenté
marital_status	catégorielle (5)	Marié, célibataire, veuf, divorcé/séparé, ne sait pas
education_level	catégorielle (6)	Aucune, primaire, secondaire, supérieur, formation professionnelle, autre/NSP
Variable	**Type**	**Description / modalités**
job_type	catégorielle (10)	Salarié du privé ou du public, indépendant, informel, agriculture/pêche, dépendant de transferts, sans revenu…

Tableau 2 - Dictionnaire des variables du fichier brut (8 des 11 variables explicatives sont catégorielles)

3. Qualité des données

Contrôle	Résultat	Décision
Valeurs manquantes	0 dans toutes les colonnes (Train et Test)	Rien à imputer
Lignes entièrement identiques (avec uniqueid)	0	-

Unicité de *uniqueid*	Seulement 8 735 valeurs distinctes pour 23 524 lignes : l'identifiant se répète d'un pays à l'autre. La paire (pays, uniqueid) est en revanche unique.	Création de **id_unique** = pays + uniqueid
Recouvrement Train / Test	Aucun identifiant commun, mêmes modalités dans les deux fichiers	Pas de fuite de données par l'identifiant
Lignes identiques hors identifiant (variables explicatives + cible)	4 429 (18,8 %)	Conservées : voir remarque ci-dessous
Profils contradictoires	484 profils (1 746 personnes) ont les mêmes 11 caractéristiques mais des étiquettes différentes	Bruit irréductible, à garder en tête pour interpréter les performances (sections 8 et 9)
Fautes et libellés	« Divorced/Seperated » (faute), trois formulations de « ne sait pas »	Corrigés et regroupés en « Unknown » (8 + 35 + 126 lignes)
Âge	Minimum 16 ans (seuil de l'enquête), 939 répondants de moins de 18 ans (4,0 %), 241 de plus de 83 ans (règle de Tukey), 57 de plus de 90 ans	Conservés, indicateur **flag_age_outlier**
Taille du ménage	381 ménages de plus de 9 personnes (règle de Tukey), maximum 21	Conservés, indicateur **flag_hh_outlier**
Cohérence âge / rôle	25 mineurs « chef de ménage » et 15 mineurs « conjoint »	Conservés, indicateur **flag_age_role** (40 lignes)
Modalité « Parent »	Âge médian de 21 ans, proche de celui des « enfants » (20 ans) : le libellé semble inversé ou ambigu	À traiter comme une simple catégorie, sans interprétation
Cohérence emploi / éducation / revenu	37 salariés formels sans instruction, 13 personnes « sans revenu » bancarisées : cas rares et plausibles	Aucune action

Tableau 3 - Audit de qualité du fichier Train

Pourquoi ne pas supprimer les « doublons » ? Les variables sont presque toutes catégorielles avec peu de modalités : deux personnes différentes peuvent légitimement avoir exactement le même profil. Supprimer ces lignes ferait perdre 18,8 % de l'échantillon et fausserait les taux observés. En revanche, la présence de profils identiques à étiquettes contradictoires signifie qu'aucun modèle ne pourra atteindre une performance parfaite avec ces seules variables.

Cohérence Train / Test. Les deux fichiers ont des distributions très proches (écart maximal de l'ordre d'un point de pourcentage sur la part de chaque modalité, âge moyen 38,8 contre 38,3 ans, mêmes pays dans les mêmes proportions). Un modèle entraîné sur Train devrait donc se généraliser sans décalage de distribution sur Test.

4. Statistiques descriptives

Variable	Moyenne	Écart-type	Min	Médiane	Max	Asymétrie
age_of_respondent	38,8	16,5	16	35	100	0,84
household_size	3,80	2,23	1	3	21	0,99

Tableau 4 - Variables numériques (Train)

Les deux variables sont asymétriques à droite : beaucoup de jeunes adultes et de petits ménages, avec une longue traîne de personnes âgées et de grands ménages. La corrélation de Pearson entre l'âge et la

cible n'est que de 0,02 et celle entre la taille du ménage et la cible de -0,03 : cela ne signifie pas l'absence de lien, mais un lien non linéaire (voir section 5.3).

Côté catégoriel, le répondant type est un habitant rural (61 %), une femme (59 %), avec un téléphone (74 %), un niveau d'éducation primaire (54 %), chef de ménage (55 %) ou conjoint (28 %), travaillant à son compte, dans l'informel ou dans l'agriculture et la pêche (environ 74 % à eux trois). Les diplômés du supérieur (4,9 %) et les salariés du secteur formel (6,1 %) sont rares.

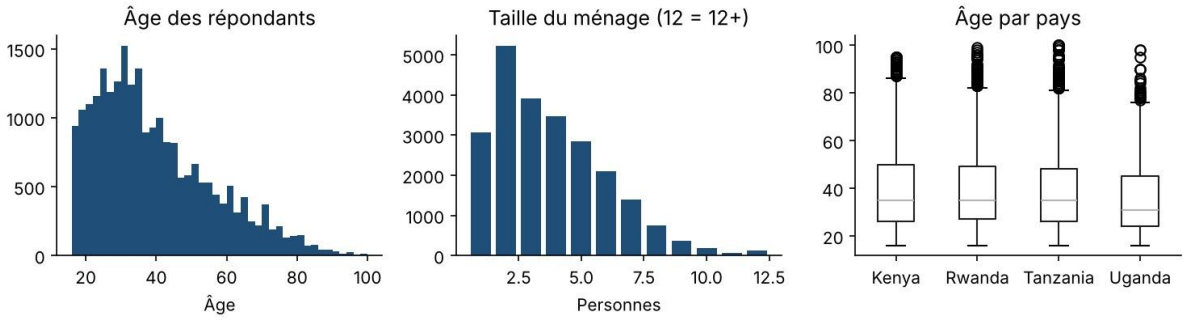


Figure 1 - Distribution de l'âge, de la taille du ménage et de l'âge par pays

5. Visualisations et premiers enseignements

5.1 Une cible fortement déséquilibrée, et de grandes différences entre pays

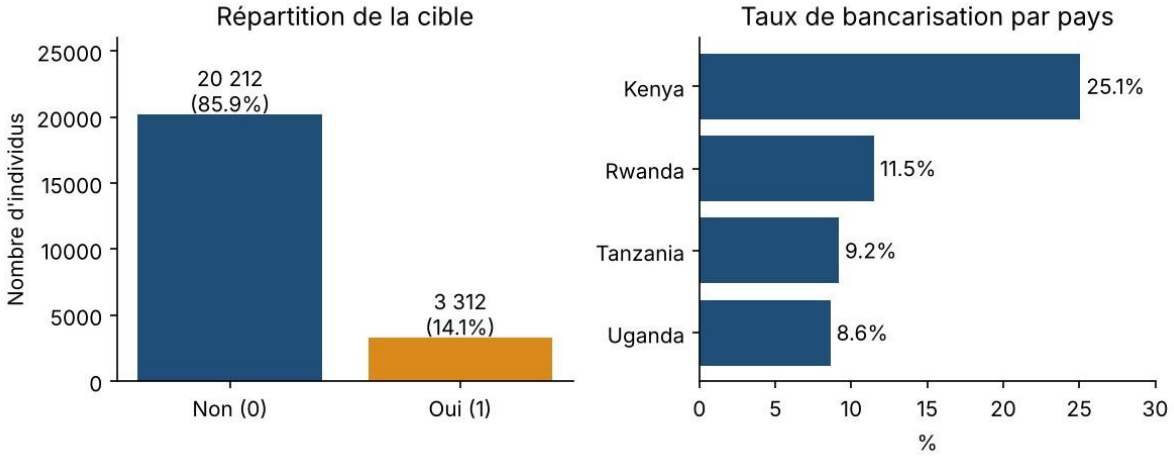


Figure 2 - Répartition de la variable cible et taux de bancarisation par pays

Seuls **14,1 %** des répondants ont un compte (environ 1 répondant sur 7, soit 6 non-bancarisés pour 1 bancarisé). Le Kenya se détache nettement avec 25,1 %, alors que le Rwanda (11,5 %), la Tanzanie (9,2 %) et l'Ouganda (8,6 %) sont proches les uns des autres. Une hypothèse plausible, qui ne peut pas être démontrée avec ces données, est le rôle de l'écosystème de mobile money kényan ; il faut aussi garder en tête que les pays diffèrent par leur composition (la Tanzanie compte 73 % d'urbains, le Rwanda seulement 14 %).

5.2 Éducation et situation professionnelle : les facteurs les plus discriminants

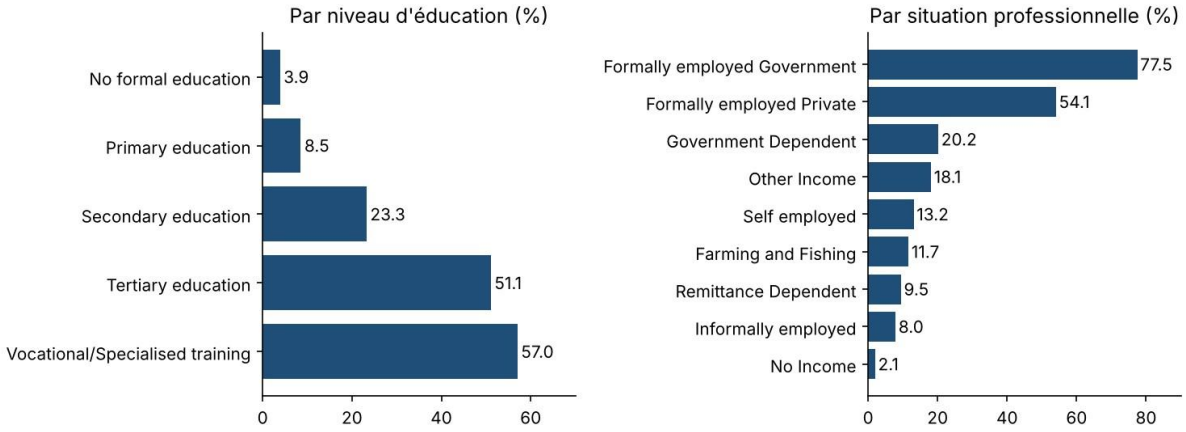


Figure 3 - Taux de bancarisation par niveau d'éducation et par situation professionnelle

Le taux de bancarisation passe de **3,9 %** sans instruction formelle à 8,5 % au primaire, 23,3 % au secondaire, 51,1 % dans le supérieur et 57,0 % après une formation professionnelle. Côté emploi, les salariés du gouvernement (77,5 %) et du privé (54,1 %) sont très loin devant les indépendants (13,2 %), les travailleurs de l'agriculture et de la pêche (11,7 %), les travailleurs informels (8,0 %) et les personnes sans revenu (2,1 %). Ces deux variables ont les plus fortes associations avec la cible (V de Cramér de 0,39 et 0,36, figure 7). Elles sont probablement liées entre elles : un emploi formel passe souvent par un compte pour le versement du salaire.

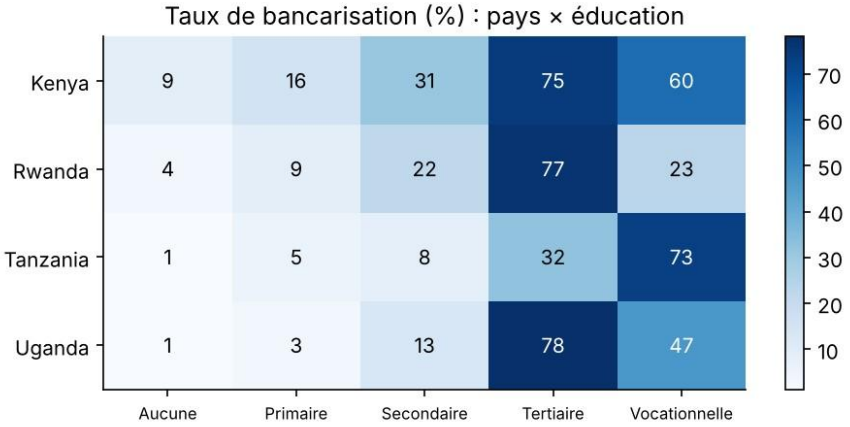


Figure 4 - Taux de bancarisation (%) selon le pays et le niveau d'éducation

La carte de chaleur montre que le gradient éducatif se retrouve dans les quatre pays, mais à des niveaux très différents : au Kenya, même sans instruction formelle on observe 8,6 % de comptes, contre 1,3 % en Tanzanie et en Ouganda. À niveau d'éducation égal, le pays garde donc un effet propre. Les très petits effectifs (par exemple l'éducation supérieure en Ouganda) imposent de la prudence sur certaines cases.

5.3 L'âge : une relation en cloche

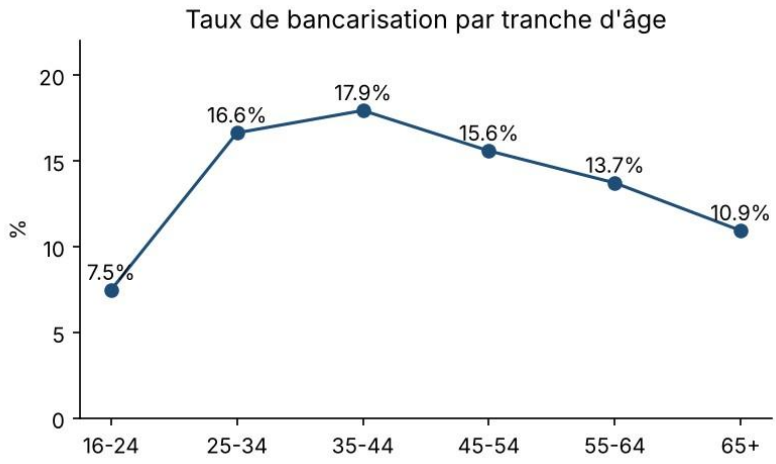


Figure 5 - Taux de bancarisation par tranche d'âge

Le taux monte de 7,5 % chez les 16-24 ans à un maximum de **17,9 % entre 35 et 44 ans**, puis décroît jusqu'à 10,9 % après 65 ans. Cette forme en cloche explique la faible corrélation linéaire : l'âge devra être traité de façon non linéaire (modèles à arbres, ou découpage en classes comme la colonne *age_group* fournie).

5.4 Téléphone, milieu de vie et genre

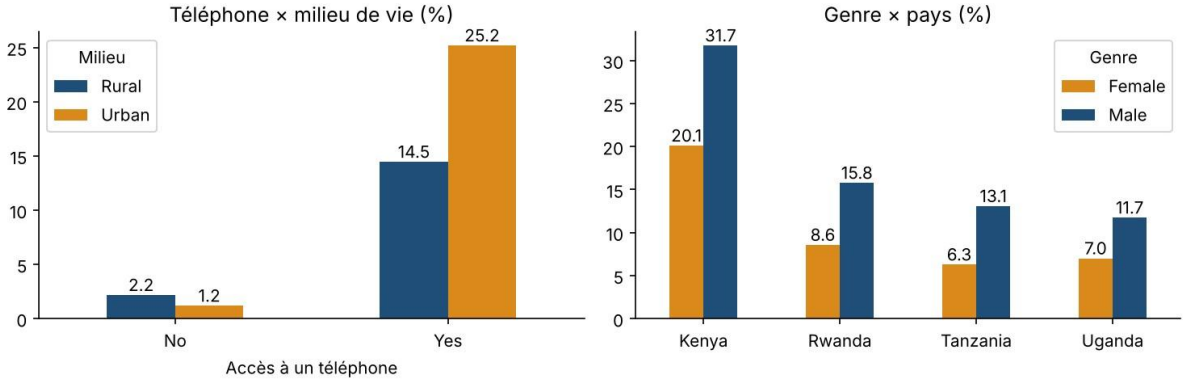


Figure 6 - Bancarisation selon le téléphone et le milieu de vie, et selon le genre et le pays

Téléphone : 18,4 % des personnes ayant un téléphone sont bancarisées contre 1,7 % de celles qui n'en ont pas. C'est l'écart le plus net de tout le jeu de données pour une variable binaire. Le téléphone est probablement un intermédiaire d'accès (mobile money, application bancaire), mais aussi un marqueur de niveau de vie.

Milieu de vie : les urbains sont plus bancarisés (17,9 %) que les ruraux (11,7 %). L'effet est cependant moins fort qu'il n'y paraît : chez les personnes sans téléphone, les urbains ne sont pas mieux lotis que les ruraux (1,2 % contre 2,2 %). L'avantage urbain se concentre chez ceux qui ont un téléphone (25,2 % contre 14,5 %).

Genre : les hommes (19,0 %) sont plus bancarisés que les femmes (10,7 %), et l'écart se retrouve dans chaque pays (par exemple 31,7 % contre 20,1 % au Kenya, 15,8 % contre 8,6 % au Rwanda). Une partie de cet écart peut venir des différences d'éducation et d'emploi, ce que la modélisation permettra de tester en comparant l'effet du genre avec et sans ces variables.

5.5 Autres variables

Les chefs de ménage sont plus souvent bancarisés (17,7 %) que les conjoints (10,7 %), les enfants (8,7%) et les « parents » (6,0 %) ; les personnes mariées (17,4 %) le sont plus que les veufs (9,0 %). La taille du ménage a un effet faible : les personnes vivant seules ont un taux de 19,1 %, puis le taux se stabilise autour de 12 à 15 % pour 2 à 7 personnes et baisse pour les grands ménages.

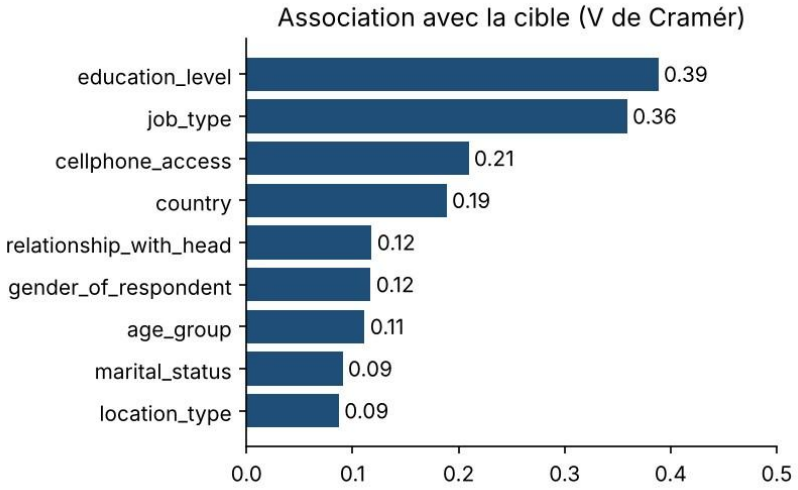


Figure 7 - Force d'association de chaque variable avec la cible (V de Cramér). Tous les tests du khi-deux ont une p-valeur inférieure à 10 puissance -40.

6. Hypothèses formulées

N°	Hypothèse	Appui dans les données	Test prévu en modélisation
H1	Le niveau d'éducation et l'emploi formel sont les meilleurs prédicteurs	V = 0,39 et 0,36 ; écarts de 4 % à 57 % et de 2 % à 78 %	Importance des variables, effet à pays et téléphone égaux
H2	L'accès au téléphone est la porte d'entrée vers le compte	1,7 % contre 18,4 %	Interactions téléphone × milieu et téléphone × pays
H3	Le pays a un effet propre, surtout pour le Kenya	25,1 % contre 8,6-11,5 %, gradient éducatif décalé	Performance du modèle sans la variable pays
H4	Un écart de genre subsiste à profil équivalent	Hommes 19,0 % / femmes 10,7 %, dans les 4 pays	Importance du genre une fois éducation et emploi inclus
H5	L'âge agit de façon non linéaire (maximum 35-44 ans)	7,5 % / 17,9 % / 10,9 % selon la tranche	Comparer régression logistique et modèles à arbres
H6	L'effet urbain passe en grande partie par le téléphone et le niveau de vie	Pas d'avantage urbain sans téléphone	Coefficients avec et sans le téléphone

Tableau 5 - Hypothèses issues de l'EDA (verdicts : tableau 11)

7. Nettoyage effectué et jeu de données livré

Opération	Détail
Recodage de la cible	bank_account : Yes = 1, No = 0
Identifiant unique	id_unique = pays + « _ » + uniqueid (remplace uniqueid)
Harmonisation des libellés	« Divorced/Seperated » devient « Divorced/Separated » ; les trois formes de « ne sait pas / refus » deviennent « Unknown »
Nouvelle variable	age_group : 16-24, 25-34, 35-44, 45-54, 55-64, 65+
Indicateurs de cas atypiques	flag_age_role (40), flag_age_outlier (241), flag_hh_outlier (381) : informatifs, aucune ligne supprimée
Lignes conservées	23 524 sur 23 524, aucune valeur manquante, id_unique unique

Tableau 6 - Opérations de nettoyage (notebook EDA_Inclusion_Financiere.ipynb)

Le fichier **train_clean.csv** contient 17 colonnes : id_unique, country, year, location_type, cellphone_access, household_size, age_of_respondent, age_group, gender_of_respondent, relationship_with_head, marital_status, education_level, job_type, flag_age_role, flag_age_outlier, flag_hh_outlier, bank_account (cible, en dernière colonne).

Synthèse de l'analyse exploratoire

Cette première phase du projet pose le problème métier (qui est exclu du système bancaire en Afrique de l'Est, et pourquoi chercher à le prédire), décrit et audite le jeu de données Zindi, puis le nettoie en vue de la modélisation. Les principaux enseignements sont les suivants.

- **Déséquilibre marqué de la cible** : seulement 14,1 % des 23 524 répondants possèdent un compte bancaire (3 312 contre 20 212). Un modèle qui répondrait toujours « non » aurait 85,9 % d'accuracy : cette métrique est donc inutilisable seule.
- **Données propres mais pas sans pièges** : aucune valeur manquante, mais l'identifiant *uniqueid* n'est pas unique (il se répète d'un pays à l'autre), 484 profils identiques portent des étiquettes contradictoires, et la modalité « Parent » de la variable de relation est sémantiquement douteuse.
- **Les facteurs les plus associés au fait d'avoir un compte** sont le niveau d'éducation (V de Cramer = 0,39), la situation professionnelle (0,36), l'accès à un téléphone (0,21) et le pays (0,19). L'âge a un effet non linéaire (maximum entre 35 et 44 ans).
- **Écarts spectaculaires** : 51 % des diplômés du supérieur et 78 % des agents du gouvernement sont bancarisés, contre 4 % sans instruction formelle et 1,7 % des personnes sans téléphone.
- **Limite structurelle** : chaque pays a été enquêté une seule année (sauf Kenya et Ouganda, tous deux en 2018), donc l'effet « pays » est confondu avec l'effet « année ».
- **Livrable** : 23 524 lignes conservées (aucune suppression), variables harmonisées, cible recodée en 0/1, identifiant unique reconstruit, trois indicateurs de cas atypiques.

8. Prétraitement et modélisation

Cette section décrit la construction du modèle, depuis le choix des algorithmes jusqu'à la sélection du modèle final. Elle suit exactement le notebook pretraitement_modelisation.ipynb ; tous les chiffres cités en sont issus.

8.1 Choix des algorithmes et des métriques

Trois familles d'algorithmes ont été retenues, du plus simple au plus flexible :

- **Régression logistique** : modèle de référence, rapide et interprétable (les coefficients se lisent comme des rapports de cotes). Son défaut est de supposer des effets additifs : la relation en cloche de l'âge doit donc lui être fournie sous forme de classes (age_group).
- **Random Forest** (200 arbres) : capte seul les non-linéarités et les interactions (par exemple téléphone × pays) sans qu'on ait à les spécifier, mais peut être sensible au bruit des profils contradictoires identifiés dans l'EDA.
- **XGBoost** (boosting d'arbres, 200 arbres, profondeur 4, taux d'apprentissage 0,05) : référence sur les données tabulaires, avec une pondération native de la classe minoritaire (scale_pos_weight).

Comme 85,9 % des personnes n'ont pas de compte, l'accuracy est trompeuse (un modèle répondant toujours « non » l'atteint). Les modèles sont donc comparés sur l'**Average Precision** (critère de classement, adaptée aux classes déséquilibrées), complétée par la précision, le rappel et le F1 de la classe « a un compte », la balanced accuracy et, pour le test final, le ROC-AUC.

8.2 Prétraitement et feature engineering

Le fichier d'entrée est train_clean.csv (23 524 lignes, 17 colonnes) produit par l'EDA. Le tableau 7 indique le rôle de chaque colonne. Les variables construites lors de l'EDA (age_group et les trois indicateurs flag_*) constituent le feature engineering du projet ; l'année est retirée car elle est entièrement déterminée par le pays (Kenya et Ouganda étant tous deux enquêtés en 2018).

Rôle	Colonnes	Traitement
Cible	bank_account (0/1)	Séparée des variables explicatives
Retirées	id_unique, year	Identifiant sans valeur prédictive ; année redondante avec le pays
Numériques (5)	household_size, age_of_respondent, flag_age_role, flag_age_outlier, flag_hh_outlier	Standardisation (StandardScaler) ; les trois indicateurs sont des variables 0/1
Catégorielles (9)	country, location_type, cellphone_access, age_group, gender_of_respondent, relationship_with_head, marital_status, education_level, job_type	Encodage one-hot (OneHotEncoder, modalités inconnues ignorées)
Résultat	14 variables d'entrée	48 colonnes après encodage

Tableau 7 - Variables utilisées par le modèle et prétraitements appliqués

Le prétraitement est intégré au pipeline scikit-learn : il est ajusté uniquement sur les données d'entraînement (et, en validation croisée, sur chaque pli d'entraînement), ce qui évite toute fuite d'information vers les données d'évaluation. Le niveau d'éducation est traité comme une variable nominale ; un codage ordinal reste une piste d'amélioration.

8.3 Séparation des données

Test.csv ne contient pas la cible : l'évaluation se fait donc sur une partie de train_clean.csv mise de côté. Le découpage est de 80 % / 20 % (graine 42), stratifié sur le croisement pays × cible, ce qui préserve à la fois la répartition entre pays et le taux de bancarisation : l'ensemble d'entraînement compte 18 819 personnes (2 650 avec un compte, soit 14,08 %) et l'ensemble de test 4 705 personnes (662 avec un compte, soit 14,07 %). Le jeu de test n'est utilisé qu'une seule fois, pour l'évaluation finale.

8.4 Gestion du déséquilibre des classes

Les classes sont dans un rapport de 6,1 contre 1 (85,92 % de « non », 14,08 % de « oui »). Quatre stratégies ont été comparées : aucun rééquilibrage ; pondération des classes (`class_weight="balanced"`, et `scale_pos_weight` pour XGBoost) ; suréchantillonnage aléatoire de la classe minoritaire ; sous-échantillonnage aléatoire de la classe majoritaire. Les rééchantillonnages sont appliqués uniquement sur les données d'entraînement de chaque pli, jamais sur les données de validation.

8.5 Entraînement et comparaison des modèles

Six configurations ont été évaluées par validation croisée stratifiée à 5 plis (mélange activé, graine 42) sur l'ensemble d'entraînement. Le tableau 8 présente les moyennes sur les cinq plis, classées par Average Precision.

Configuration	Précision	Rappel	F1	Balanced acc.	Average Precision
XGBoost - pondération	0,3774	0,7600	0,5042	0,7770	**0,5863**
Régression logistique - sans rééquilibrage	0,6758	0,3396	0,4519	0,6564	0,5654
Régression logistique - pondération	0,3781	0,7404	0,5005	0,7702	0,5632
Régression logistique - suréchantillonnage	0,3750	0,7434	0,4985	0,7701	0,5628
Régression logistique - sous-échantillonnage	0,3695	0,7442	0,4936	0,7677	0,5605
Random Forest - pondération	0,4174	0,5483	0,4739	0,7114	0,4416

Tableau 8 - Validation croisée à 5 plis (classe « a un compte »)

Trois enseignements se dégagent. (1) **XGBoost pondéré** obtient la meilleure Average Precision (0,5863) et le meilleur F1 (0,5042). (2) Sans rééquilibrage, la régression logistique est la plus précise (0,6758) mais ne retrouve que 34 % des personnes bancarisées : elle est peu adaptée à un objectif de repérage. (3) Les trois stratégies de rééquilibrage appliquées à la régression logistique donnent des résultats quasi identiques (Average Precision entre 0,5605 et 0,5632) ; l'important est de rééquilibrer, pas la méthode choisie. Le Random Forest est nettement en retrait (0,4416). Ses résultats peuvent varier légèrement d'un environnement logiciel à l'autre (une réexécution du notebook sous Python 3.12 a donné une Average Precision de 0,479), alors que ceux de la régression logistique et de XGBoost sont identiques ; ce point ne change pas le choix du modèle.

8.6 Sélection du modèle final

XGBoost avec pondération des classes est retenu : meilleur compromis rappel / précision sur la validation croisée et meilleure Average Precision. Il est entraîné sur l'ensemble d'entraînement (18 819 personnes) puis évalué sur le jeu de test (section 9). Le pipeline complet (prétraitement + modèle) est sauvegardé dans `modeles/modele_inclusion_financiere.joblib` et la liste des 14 variables d'entrée dans `modeles/colonnes_entree.json`, pour être chargés par l'application (section 10).

9. Évaluation et résultats

9.1 Performances sur le jeu de test

Le tableau 9 présente les performances du modèle final sur les 4 705 personnes du jeu de test, avec le seuil de décision par défaut (probabilité ≥ 0,5).

Métrique	Valeur	Lecture
Accuracy	78,83 %	Inférieure à celle d'un modèle « toujours non » (85,9 %) : conséquence volontaire de la pondération, qui sacrifie des « non » pour retrouver les « oui »
Balanced accuracy	78,02 %	Moyenne du rappel des deux classes
Rappel (classe 1)	76,89 %	509 personnes bancarisées retrouvées sur 662
Précision (classe 1)	37,65 %	Parmi les 1 352 personnes prédites « a un compte », 509 en ont réellement un
F1 (classe 1)	50,55 %	Compromis précision / rappel
Average Precision	57,94 %	Contre 14,07 % pour un classement au hasard (environ 4 fois mieux)
ROC-AUC	86,60 %	Bonne capacité à classer une personne bancarisée devant une non bancarisée

Tableau 9 - Performances du modèle final sur le jeu de test

9.2 Matrice de confusion

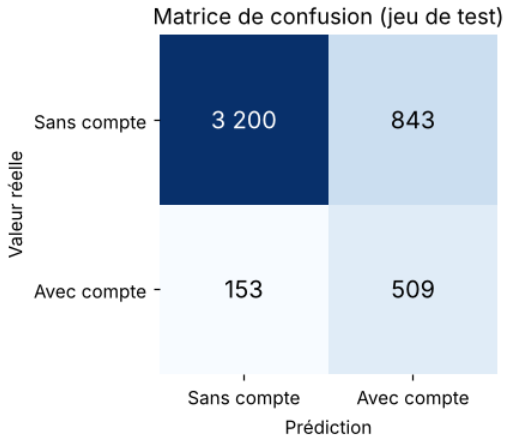


Figure 8 - Matrice de confusion du modèle final (jeu de test)

Le modèle classe correctement 3 200 personnes sans compte et 509 personnes avec compte ; il commet 843 faux positifs et 153 faux négatifs. Il déclare « a un compte » 28,7 % des personnes alors que 14,1 % seulement en ont un : le modèle privilégie le rappel. Les faux positifs ne sont pas qu'une erreur : ils désignent des personnes dont le profil ressemble à celui des personnes bancarisées mais qui n'ont pas de compte, c'est-à-dire une cible possible pour des campagnes d'inclusion (interprétation à valider sur le terrain).

9.3 Courbes ROC et précision-rappel

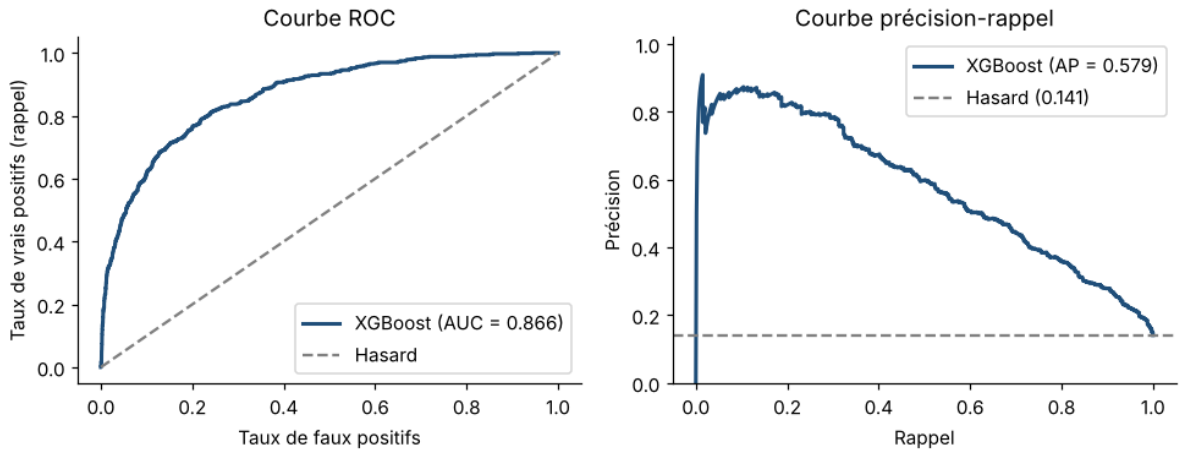


Figure 9 - Courbe ROC et courbe précision-rappel (jeu de test)

Sur des classes déséquilibrées, la courbe précision-rappel est plus informative que la courbe ROC. Elle montre que la précision décroît régulièrement quand on cherche à retrouver davantage de personnes bancarisées : la précision reste proche de 0,8 pour un rappel faible, puis tombe vers 0,2 lorsque presque toutes les personnes bancarisées sont retrouvées.

9.4 Choix du seuil de décision

Le seuil de 0,5 n'est pas imposé : il peut être relevé pour gagner en précision au prix du rappel. Le tableau 10 montre ce compromis sur le jeu de test.

Seuil	Précision	Rappel	F1	Part de personnes prédites « compte »
0,5	37,6 %	76,9 %	50,5 %	28,7 %
0,6	45,9 %	68,7 %	55,1 %	21,1 %
0,7	53,5 %	56,3 %	54,9 %	14,8 %
0,8	64,9 %	41,5 %	50,6 %	9,0 %

Tableau 10 - Précision, rappel et F1 selon le seuil de décision (jeu de test)

Un seuil de 0,6 améliore le F1 (55,1 % contre 50,5 %) en conservant un rappel de 68,7 %. Le bon seuil dépend de l'usage : bas pour une campagne de sensibilisation de masse, plus élevé pour un ciblage coûteux (démarchage individuel). Ces valeurs sont calculées sur le jeu de test : en production, le seuil devrait être fixé sur des données de validation distinctes. Le modèle livré conserve le seuil par défaut de 0,5.

9.5 Importance des variables

L'importance est mesurée par permutation sur le jeu de test : on mélange aléatoirement les valeurs d'une variable (20 répétitions) et on mesure la baisse d'Average Precision. Les variables dérivées sont regroupées avec leur variable d'origine (par exemple `age_group` avec l'âge).

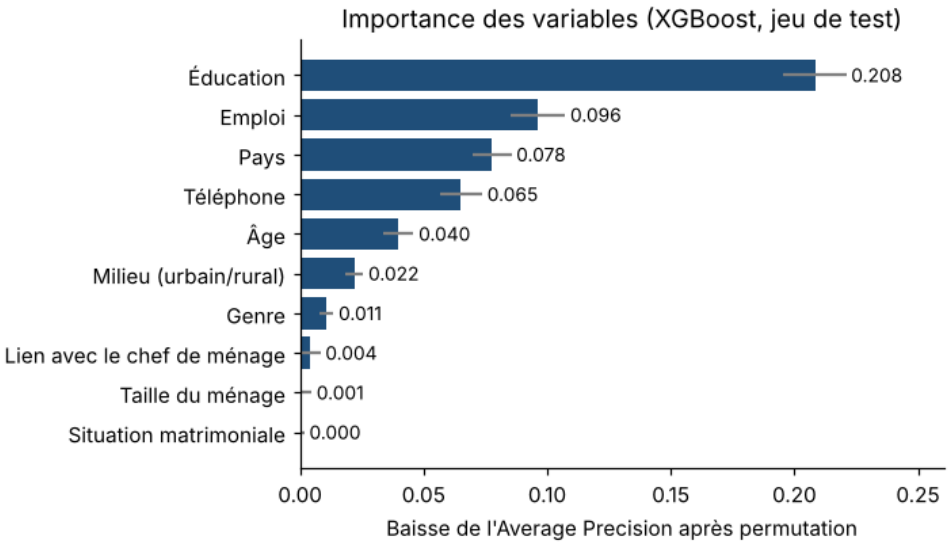


Figure 10 - Importance des variables par permutation (baisse de l'Average Precision)

L'**éducation** domine largement (baisse de 0,208), suivie de l'**emploi** (0,096), du **pays** (0,078) et du **téléphone** (0,065). L'âge (0,040) et le milieu urbain ou rural (0,022) ont un poids moindre ; le genre (0,011), le lien avec le chef de ménage, la taille du ménage et la situation matrimoniale ont un effet quasi nul une fois les autres variables connues.

9.6 Vérification des hypothèses issues de l'EDA

Les six hypothèses du tableau 5 sont confrontées aux résultats du modèle. Les rapports de cotes (odds ratios) proviennent d'une régression logistique ajustée sur l'ensemble d'entraînement ; ils décrivent des associations, pas des causes, et sont donnés sans intervalle de confiance.

N°	Résultat	Verdict
H1	Éducation (baisse d'AP de 0,208) et emploi (0,096) sont les deux variables les plus importantes. Le pays (0,078) et le téléphone (0,065) suivent de près, et pèsent plus que l'emploi sur le ROC-AUC.	**Confirmée**, avec nuance
H2	Rapport de cotes du téléphone : 12,7 sans ajustement, 5,7 après ajustement sur les autres variables. Chez les détenteurs de téléphone, 11,7 à 30,5 % ont un compte selon le pays, contre 0,5 à 4,8 % sans téléphone : l'écart existe dans les quatre pays. Les interactions téléphone × milieu et téléphone × pays n'ont pas été testées formellement.	**Confirmée**
H3	Sans la variable pays, l'Average Precision passe de 0,579 à 0,557 et le ROC-AUC de 0,866 à 0,849 : l'effet du pays est réel mais modéré. Le rôle particulier du Kenya n'est étayé que par les taux observés (30,5 % chez les détenteurs de téléphone contre 11,7 à 15,0 % ailleurs).	**Confirmée** (effet modéré)
H4	Rapport de cotes homme / femme : 1,97 sans ajustement, 1,62 sans éducation ni emploi, 1,51 avec toutes les variables. L'écart persiste à profil équivalent, mais le genre apporte peu à la prédiction (baisse d'AP de 0,011).	**Confirmée**
H5	La forme en cloche est réelle, mais en régression logistique le passage d'un âge linéaire à des classes d'âge n'améliore que très peu : AP 0,554 contre 0,551, ROC-AUC 0,856 contre 0,855. Une fois l'éducation et l'emploi connus, la non-linéarité de l'âge pèse peu.	**Partiellement confirmée**
H6	Rapport de cotes urbain / rural : 1,66 sans ajustement, 1,32 avec toutes les variables sauf le téléphone, 1,34 avec le téléphone. Ajouter le téléphone ne réduit pas l'avantage urbain, qui s'atténue surtout avec les autres variables. L'observation de l'EDA (avantage urbain concentré chez les détenteurs de téléphone) relève d'une interaction que ce modèle additif ne capte pas.	**Non confirmée**

Tableau 11 - Verdict sur les hypothèses H1 à H6

Ces vérifications, ainsi que les figures 8 à 10 et le tableau 10, sont produites par la dernière partie du notebook `pretraitement_modelisation.ipynb` (« Analyses complémentaires »), qui réutilise le jeu de test et le modèle final définis plus haut dans le même notebook.

10. Déploiement et automatisation

Cette section décrit la mise à disposition du modèle sous forme d'application, son réentraînement automatique et sa conteneurisation. L'ensemble du code est publié dans le dépôt GitHub public du projet : https://github.com/Othniel-Ken/financial-inclusion-africa. Le comportement décrit a été vérifié en exécutant le code du dépôt avec les versions de bibliothèques de `requirements.txt` (la construction des conteneurs Docker n'est pas couverte par cette vérification, voir section 10.5).

10.1 Vue d'ensemble

Le système comporte deux chaînes qui partagent le même fichier de modèle. La chaîne de **prédiction** : le formulaire web envoie les réponses à l'API, qui charge le modèle, calcule la probabilité et renvoie le résultat. La chaîne de **réentraînement** : chaque jour à 2 h, un planificateur lance un script qui entraîne un nouveau modèle et ne remplace l'ancien que s'il est meilleur ; l'API détecte le changement de fichier et utilise le nouveau modèle sans redémarrage. Le tableau 12 présente l'organisation du dépôt.

Fichier ou dossier	Rôle
`app/main.py`	API FastAPI : validation des entrées, calcul des variables dérivées, prédiction

Fichier ou dossier	Rôle
app/static/index.html	Formulaire web servi par l'API
models/	Modèle (modele_inclusion_financiere.joblib) et liste des 14 colonnes attendues (colonnes_entree.json)
scripts/retrain.py	Réentraînement et comparaison avec le modèle en place
scripts/scheduler.py	Planificateur : lance retrain.py chaque jour à 2 h
scripts/train_dummy.py	Génère des données et un modèle fictifs de démonstration ; non utilisé par l'application
Dockerfile, docker-compose.yml	Image Docker et deux services : API et planificateur
requirements.txt	Versions exactes des bibliothèques (scikit-learn 1.8.0, XGBoost 3.4.1, imbalanced-learn 0.14.2, FastAPI, etc.)
EDA_Inclusion_Financiere.ipynb, pretraitement_modelisation.ipynb	Exploration et nettoyage ; prétraitement, modélisation, évaluation et analyses complémentaires
data/	Contient train_clean.csv ; jamais publié (voir plus bas)

Tableau 12 - Organisation du dépôt GitHub

Les outils sont : Python 3.13, FastAPI et Uvicorn (API et serveur web), Pydantic (validation des entrées), scikit-learn, XGBoost et imbalanced-learn (mêmes versions que lors de l'entraînement, indispensables pour recharger le modèle sans erreur), pandas et joblib, schedule (planification) et Docker avec Docker Compose.

10.2 API de prédiction

L'API propose trois points d'accès (tableau 13).

Adresse	Méthode	Rôle
/	GET	Affiche le formulaire web
/health	GET	Répond {"status": "ok"} : vérifie que le service tourne
/predict	POST	Reçoit les informations d'une personne et renvoie la prédiction

Tableau 13 - Points d'accès de l'API

L'API reçoit 10 informations (pays, milieu, téléphone, taille du ménage, âge, genre, lien avec le chef de ménage, situation matrimoniale, éducation, emploi). Pydantic contrôle les types et les bornes numériques (âge entre 16 et 100 ans, taille du ménage entre 1 et 30). Le modèle attend 14 colonnes : l'API ajoute les quatre variables dérivées avec exactement les règles du nettoyage de l'EDA (tableau 14) et transmet les colonnes dans l'ordre de colonnes_entree.json. Le pipeline sauvegardé contient le prétraitement : l'API lui envoie donc les valeurs brutes.

Variable d'entrée	Type	Origine
country, location_type, cellphone_access, gender_of_respondent, relationship_with_head, marital_status, education_level, job_type	Catégorielle	Saisie, avec les modalités de train_clean.csv
household_size, age_of_respondent	Numérique	Saisie
age_group	Catégorielle	Dérivée de l'âge : 16-24, 25-34, 35-44, 45-54, 55-64, 65+
flag_age_role	0 / 1	Dérivée : lien « Head of Household » ou « Spouse » et âge inférieur à 18 ans
flag_age_outlier	0 / 1	Dérivée : âge supérieur à 83 ans
flag_hh_outlier	0 / 1	Dérivée : taille du ménage supérieure à 9 personnes

Tableau 14 - Variables d'entrée du modèle et règles de dérivation (implémentées dans `app/main.py`)

L'API renvoie la probabilité estimée (probability) et une classe (has_bank_account), vraie lorsque la probabilité atteint 0,5, seuil utilisé dans l'évaluation. Le tableau 15 montre deux réponses réelles de l'API. Le score est celui d'un modèle pondéré pour la classe minoritaire (14 % de personnes bancarisées) : il surestime la probabilité réelle et se lit comme un indice de confiance. À chaque requête, l'API compare la date du fichier du modèle à celle de la dernière version chargée et le recharge s'il a changé.

Profil envoyé	Réponse de l'API
Kenya, urbain, avec téléphone, ménage de 4 personnes, 35 ans, femme, conjointe, mariée, éducation secondaire, indépendante	{"has_bank_account": true, "probability": 0.826}
Tanzanie, rural, sans téléphone, ménage de 6 personnes, 45 ans, femme, conjointe, mariée, sans éducation formelle, agriculture et pêche	{"has_bank_account": false, "probability": 0.042}

Tableau 15 - Deux exemples d'appel à `/predict`

10.3 Interface web

La page app/static/index.html est un formulaire de 10 champs : huit listes déroulantes, dont les valeurs sont exactement celles que le modèle connaît (ce qui évite les fautes de frappe), et deux champs numériques. Au clic sur « Estimer la probabilité », la page appelle /predict puis affiche un message (« possède probablement » ou « ne possède probablement pas un compte bancaire ») avec le score. Une note rappelle que l'estimation n'est ni une décision bancaire ni une probabilité individuelle garantie (figure 11).

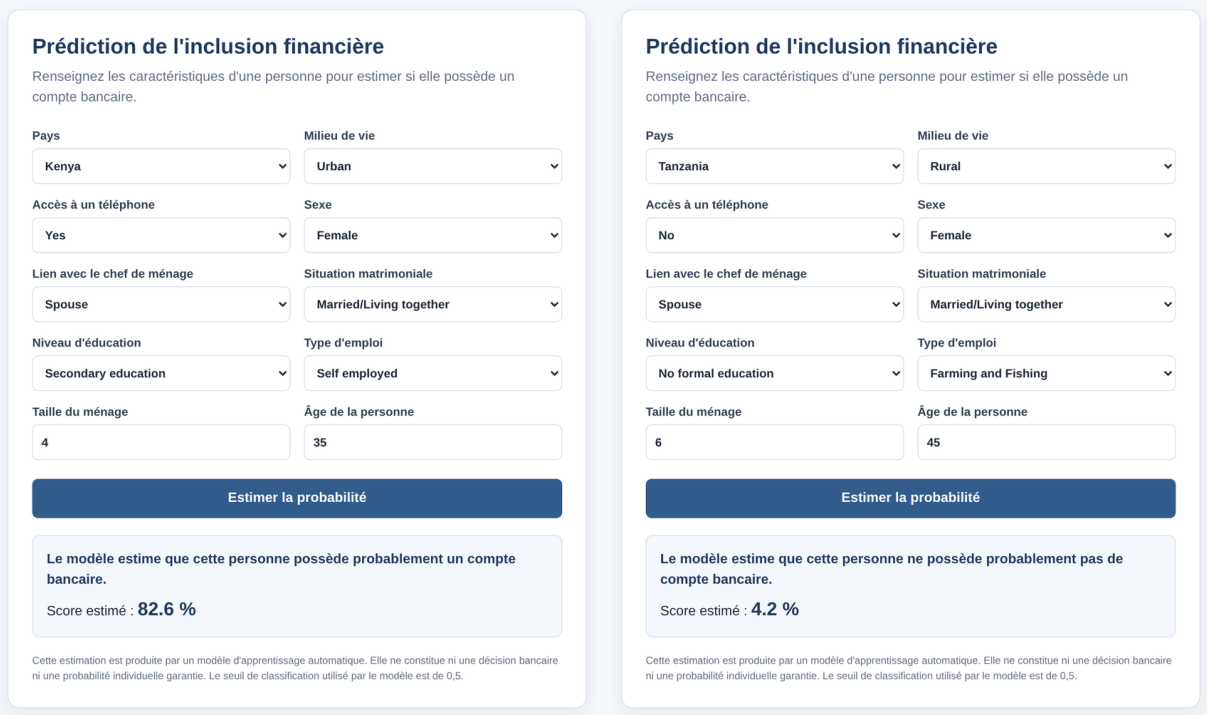


Figure 11 - Formulaire web : deux profils testés (score de 82,6 % à gauche, 4,2 % à droite)

10.4 Réentraînement automatique

Le script scripts/retrain.py procède ainsi :

- il lit data/train_clean.csv ;
- il reproduit le découpage de la modélisation (80 % / 20 %, stratifié sur pays × cible, graine 42) : l'ancien et le nouveau modèle sont comparés sur exactement les mêmes personnes de test ;
- il entraîne un nouveau XGBoost avec la même configuration que le modèle final (200 arbres, profondeur 4, taux d'apprentissage 0,05, pondération des classes) ;
- il compare les deux modèles sur l'Average Precision, critère de sélection de la modélisation ;
- si le nouveau est strictement meilleur, il copie d'abord l'ancien dans models/backups/ puis le remplace ; sinon il affiche « Ancien modèle conservé ».

Le planificateur scripts/scheduler.py (bibliothèque schedule) lance ce script tous les jours à 2 h. Un réentraînement moins bon ou raté ne peut donc pas dégrader le modèle en place, et la sauvegarde permet de revenir en arrière. Exécuté sur train_clean.csv, le script obtient pour l'ancien et le nouveau modèle la même Average Precision (0,5794) et le même ROC-AUC (0,8660) : l'ancien modèle est conservé, comportement attendu tant que les données n'ont pas changé. Le mécanisme prend tout son sens lorsque de nouvelles données sont ajoutées à data/train_clean.csv.

10.5 Conteneurisation avec Docker

Le Dockerfile construit une image à partir de python:3.13-slim, installe les bibliothèques de requirements.txt, copie l'application, les scripts et le modèle, puis lance Uvicorn sur le port 8000. Le fichier docker-compose.yml démarre deux conteneurs à partir de cette image : api (port 8000) et retrain (le planificateur). Les deux partagent le dossier models/, de sorte que le modèle réentraîné est immédiatement visible par l'API ; le dossier data/ n'est monté que sur retrain. Les commandes sont docker compose up --build pour démarrer et docker compose down pour arrêter ; l'application est alors accessible sur http://127.0.0.1:8000 (documentation interactive de l'API sur /docs). Cela suppose Docker Desktop installé et train_clean.csv

placé dans data/ pour le réentraînement. La construction et le lancement des conteneurs doivent être exécutés sur une machine disposant de Docker.

Les fichiers de données de Zindi (Train.csv, Test.csv, train_clean.csv) ne sont ni dans l'image ni dans le dépôt (.gitignore et .dockerignore excluent data/), car les règles de la compétition interdisent leur republication : ils se téléchargent sur le site de Zindi.

10.6 Reproduire le projet

- Cloner le dépôt et télécharger Train.csv et Test.csv sur Zindi.
- Exécuter EDA_Inclusion_Financiere.ipynb, qui produit train_clean.csv ; placer ce fichier dans data/
- Exécuter pretraitement_modelisation.ipynb : il entraîne le modèle, le sauvegarde dans models/ et produit les analyses complémentaires du rapport.
- Lancer l'application : pip install -r requirements.txt puis uvicorn app.main:app --reload, ou docker compose up --build.

11. Limites et perspectives

11.1 Limites

- **Pays et année confondus** : chaque pays a été enquêté une seule année (Kenya et Ouganda en 2018), l'effet « pays » ne peut donc pas être séparé de l'effet « année ».
- **Couverture** : Afrique de l'Est uniquement (le Bénin n'est pas couvert), données de 2016 à 2018, avant l'essor récent du mobile money. Les résultats ne se transposent pas tels quels à d'autres pays ou à aujourd'hui.
- **Associations, pas causalité** : éducation, emploi et téléphone sont corrélés entre eux ; ni les taux bruts ni l'importance des variables ne prouvent qu'agir sur l'une d'elles ferait gagner un compte.
- **Informations limitées et bruit irréductible** : le jeu ne contient ni revenu, ni distance à une agence, ni usage du mobile money. 484 profils identiques (1 746 personnes) portent des étiquettes contradictoires, ce qui plafonne la performance atteignable.
- **Précision faible** : à 0,5, seule une personne prédite « a un compte » sur trois est réellement bancarisée (37,65 %). Le seuil n'a pas été optimisé sur des données de validation.
- **Protocole d'évaluation** : une seule partition entraînement / test ; hyperparamètres fixés sans optimisation ; 18,8 % des lignes ont un profil identique à une autre ligne, de sorte que des profils se retrouvent à la fois dans l'entraînement et le test, ce qui peut rendre l'estimation légèrement optimiste. Le modèle livré est entraîné sur 80 % des données seulement.
- **Qualité des libellés** : la modalité « Parent » de la variable de relation est ambiguë (âge médian proche de celui des enfants).
- **Application** : l'API n'a ni authentification ni limitation d'appels, ce qui suffit pour une démonstration mais pas pour une mise en production. Elle contrôle les bornes numériques mais pas les modalités catégorielles : une valeur inconnue est acceptée (et encodée comme absente), seuls les menus déroulants du formulaire garantissent des valeurs valides. Le score renvoyé n'est pas une probabilité calibrée.
- **Réentraînement** : il n'apporte rien tant que les données ne changent pas. Si le fichier de données évolue, le découpage 80 % / 20 % change aussi : le jeu de test peut alors contenir des personnes sur lesquelles l'ancien modèle a été entraîné, ce qui l'avantage dans la comparaison. Un jeu de test figé serait préférable.

- **Dépendance aux versions** : le modèle sauvegardé ne se recharge sans problème qu'avec scikit-learn 1.8.0, XGBoost 3.4.1 et imbalanced-learn 0.14.2 (versions épinglées dans requirements.txt).
- **Usage responsable** : le modèle décrit des profils, pas des intentions individuelles. Le genre figurant parmi les variables, il ne doit pas servir à refuser un service financier à une personne.

11.2 Perspectives

- Optimiser les hyperparamètres (recherche aléatoire ou bayésienne) et fixer le seuil par validation croisée.
- Tester un codage ordinal de l'éducation, un rééchantillonnage de type SMOTE, une calibration des probabilités et des explications individuelles (SHAP).
- Enrichir les données (usage du mobile money, revenus, distance aux agences, enquêtes plus récentes) et élargir à d'autres pays, dont le Bénin.
- Renforcer l'application : validation des modalités catégorielles, authentification, tests automatisés et hébergement en ligne.
- Surveiller la dérive des données et la performance du modèle une fois en production, et ré-entraîner sur la totalité des données disponibles.

12. Conclusion

Ce projet a parcouru le cycle complet d'un projet de science des données : cadrage métier, audit et exploration de données réelles de FinScope, modélisation rigoureuse (six configurations comparées par validation croisée, évaluation sur un jeu de test tenu à l'écart) et mise à disposition du modèle dans une application avec réentraînement automatique. Le modèle retenu, un XGBoost pondéré, retrouve 77 % des personnes bancarisées (ROC-AUC de 0,866), au prix d'une précision de 38 %. Surtout, l'analyse montre que l'accès à un compte est d'abord une question d'éducation et d'emploi, puis de pays et d'accès au téléphone, avec un écart de genre qui persiste à profil équivalent. Ces résultats peuvent guider le ciblage des politiques d'inclusion financière, à condition de rester prudent sur leur portée : ils décrivent des associations observées entre 2016 et 2018 en Afrique de l'Est, non des relations de cause à effet.

Références

- Zindi Africa. *Financial Inclusion in Africa* (données issues des enquêtes FinScope 2016-2018). https://zindi.world/competitions/financial-inclusion-in-africa/data
- Pedregosa, F. et al. (2011). Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Chen, T. et Guestrin, C. (2016). XGBoost : A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.
- Lemaître, G., Nogueira, F. et Aridas, C. K. (2017). Imbalanced-learn : A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning. *Journal of Machine Learning Research*, 18(17), 1-5.
- Ramírez, S. FastAPI (documentation). https://fastapi.tiangolo.com
- Docker Inc. Docker Documentation. https://docs.docker.com
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- Saito, T. et Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. *PLOS ONE*, 10(3), e0118432.